



CS 412 Intro. to Data Mining


Chapter 2. Getting to Know Your Data

Jiawei Han, Computer Science, Univ. Illinois at Urbana-Champaign, 2017





Chapter 2. Getting to Know Your Data



- ❑ Data Objects and Attribute Types

วัตถุข้อมูลและประเภทของแอตทริบิวต์

- ❑ Basic Statistical Descriptions of Data

คำอธิบายข้อมูลทางสถิติพื้นฐาน

- ❑ Data Visualization

การแสดงผลภาพข้อมูล

- ❑ Measuring Data Similarity and Dissimilarity

การวัดความเหมือนและความต่างของข้อมูล

- ❑ Summary

บทสรุป

Types of Data Sets: (1) Record Data

- Relational records ข้อมูลแบบตารางความสัมพันธ์
- Relational tables, highly structured ข้อมูลที่เก็บในรูปแบบตารางฐานข้อมูล
- Data matrix, e.g., numerical matrix, crosstabs ข้อมูลที่เป็นเมทริกซ์ (ตารางตัวเลข)

	China	England	France	Japan	USA	Total
Active Outdoors Crochet Glove		12.00	4.00	1.00	240.00	257.00
Active Outdoors Lycra Glove		10.00	6.00		323.00	339.00
InFlux Crochet Glove	3.00	6.00	8.00		132.00	149.00
InFlux Lycra Glove		2.00			143.00	145.00
Triumph Pro Helmet	3.00	1.00	7.00		333.00	344.00
Triumph Vertigo Helmet		3.00	22.00		474.00	499.00
Xtreme Adult Helmet	8.00	8.00	7.00	2.00	251.00	276.00
Xtreme Youth Helmet		1.00			76.00	77.00
Total	14.00	43.00	54.00	3.00	1,972.00	2,086.00

Person:

Pers_ID	Surname	First_Name	City
0	Miller	Paul	London
2	Huber	Urs	Zurich
3	Blanc	Gaston	Paris
4	Bertolini	Fabrizio	Rom

Car:

Car_ID	Model	Year	Value	Pers_ID
101	Bentley	1973	100000	0
102	Rolls Royce	1965	330000	0
103	Peugeot	1993	500	3
104	Ferrari	2005	150000	4
105	Renault	1998	2000	3
106	Renault	2001	7000	3
107	Smart	1999	2000	2

no relation

- Transaction data ข้อมูลรายการธุรกรรม

TID	Items
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

	team	coach	y	pla	ball	score	game	wi	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2	
Document 2	0	7	0	2	1	0	0	3	0	0	
Document 3	0	1	0	0	1	2	2	0	3	0	

- Document data: Term-frequency vector (matrix) of text documents ข้อมูลเอกสาร

ข้อมูลส่วนใหญ่ที่เราเจอคือ Record Data แต่หน้าตามันเปลี่ยนไปตามการใช้งาน:
 ถ้าเก็บประวัติทั่วไป -> Relational Table
 ถ้าเก็บการซื้อของ -> Transaction Data
 ถ้าเก็บข้อความ/บทความ -> Document Data (Term-frequency)


Types of Data Sets: (2) Graphs and Networks

□ Transportation network เครือข่ายการคมนาคม

การนำไปใช้: หาเส้นทางที่สั้นที่สุด (Shortest Path) เหมือนที่ Google Maps ทำ หรือวิเคราะห์จุดคับขวดของการจราจร

□ World Wide Web เครือข่ายเว็บ

การนำไปใช้: Algorithm อย่าง PageRank ของ Google ก็ใช้ข้อมูลส่วนนี้มาคำนวณว่าหน้าเว็บไหน "สำคัญ" โดยดูว่ามีเส้น (Link) ชี้มาหาเยอะแค่ไหน



□ Molecular Structures โครงสร้างโมเลกุล

การนำไปใช้: ในวงการยา ใช้คอมพิวเตอร์ค้นหาโครงสร้างโมเลกุลย่อย (Substructure Mining) เพื่อดูว่าโครงสร้างแบบไหนมีคุณสมบัติรักษาโรคได้

□ Social or information networks เครือข่ายสังคม

การนำไปใช้:

- Community Detection: หาวาใครอยู่แ่งเดียวกัน
- Influencer Marketing: หาวาใครเป็นจุดศูนย์กลางที่มีเส้นเชื่อมเยอะที่สุด (มีอิทธิพลต่อคนอื่นมากที่สุด)




Types of Data Sets: (3) Ordered Data

ข้อมูลวิดีโอ

- Video data: sequence of images

คือ "ลำดับของภาพนิ่ง" (Sequence of images/frames) ที่เรียงต่อกันตามเวลา

- Temporal data: time-series
ข้อมูลอนุกรมเวลา



คือ ข้อมูลที่มี "เวลา" กำกับทุกค่า และมักเก็บในช่วงเวลาที่แน่นอน (เช่น ทุกชั่วโมง, ทุกวัน)

ตัวอย่าง: ราคาน้ำมันรายวัน, ยอดขายรายเดือน, กราฟหุ้น
สำคัญ: ใช้ดูแนวโน้ม (Trend) และฤดูกาล (Seasonality)



- Sequential Data: transaction sequences
ข้อมูลลำดับเหตุการณ์

เน้น "ลำดับการกระทำ" ว่าทำอะไรก่อน-หลัง (Event Sequence)

ตัวอย่าง: ลูกค้าซื้อคอมพิวเตอร์ จากนั้น ซื้อโปรแกรม จากนั้น ซื้อเครื่องพริ้นเตอร์ (Transaction Sequences)

ข้อสังเกต: ต่างจาก Transaction ปกติที่ดูแค่ว่า "ในตะกร้ามีอะไรบ้าง" (ไม่สนใจลำดับ) แต่อันนี้สนใจว่า "หยิบอะไรใส่ก่อนหลัง"

- Genetic sequence data
ข้อมูลลำดับพันธุกรรม

คือ ข้อมูลสายยาวของรหัสพันธุกรรม (DNA/RNA)

ตัวอย่าง: การเรียงตัวของเบส A, C, G, T (...AGCTAGCC...)

สำคัญ: การเรียงลำดับกำหนดลักษณะทางชีวภาพ ถ้าวัดสลับที่แค่นี้เดียว อาจกลายพันธุ์ได้


Start

Human	GTTTGGAGG -- - ATGTTCAACAAATGCTCCTTTTCATTCTCTATTTACAGACCTGCCGCA
Chimpanzee	GTTTGGAGG -- - ATGTTCAATAAATGCTGCTTTTCACCTCTCTATTTACAGACCTGCCGCA
Macaque	GTTTGGAGG -- - ATGTTCAATAAATGCTCCTTTTCATTCTCTATTTACAAACTTGCCGCA
Human	GACAATTCTGCTAGCAGCC TTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Chimpanzee	GACAATTCTGCTAGCAGCC TTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Macaque	GACAATTCTGCTAGCAGCC TTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Human	GATCTGGAGACTAA - CTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Chimpanzee	GATCTGGAGACTAAACTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Macaque	TATCTGGAGACTAAACTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Human	CAGAATACGATTTAGCAAAATTACTTCTTAAGATATTATTTTACATTTCTATATTCTCCTA
Chimpanzee	CAGAATACGATTTAGCAAAATTACTTCTTAAGATATTATTTTACATTTCTATATTCTCCTA
Macaque	CAGAATATGATTTAGCAAAATTACTTCTTAAGATATTATTTTGCATTTCTATATTCTCCTA
Human	CCCTGAGTTGATGTGTGAGCAATATGTCACCTTTTCATAAAGCCAGGTATACA --- TTATG
Chimpanzee	CCCTGAGTTGATGTGTGAGCCGATATGTCACCTTTTCATAAAGCCAGGTATACA --- TTATG
Macaque	CCCTGAGTTGATGTGTGAGCAATATGTCACCTTTTCATAAAGCCAGGTATATATACATTACG
Human	GACAGGTAAGTAAAAACATATTATTTATTCTACGTTTTTGCCAAAAATTTTAAATTTT
Chimpanzee	GACAGGTAAGTAAAAACATATTATTTATTCTACGTTTTTGCCAAAGATTTTAAATTTT
Macaque	GACAGGTAAGTAAAAA - CATATTATTTATTCTAGGTTTTTGCCAAAGATTTTAAATTTT
Human	AACGTGTTGCGCGTGTGTTGGTAA --- TGTAAAACAAAC TCAGTACAG
Chimpanzee	AACGTGTTGCGCGTGTGTTGGTAA --- TGTAAAACAAAC TCAGTACAG
Macaque	AACGTGTTGTCATGTGTTGGTAA --- CGTAAAACAAATTCAGTACG

Types of Data Sets: (4) Spatial, image and multimedia Data

ข้อมูลเชิงพื้นที่/แผนที่

□ Spatial data: maps



□ Image data: ข้อมูลรูปภาพ

คอมพิวเตอร์มองรูปภาพเป็น "ตารางของจุดสี" (Matrix of Pixels)
โครงสร้าง: แต่ละจุด (Pixel) จะมีค่าตัวเลขแทนสี (เช่น RGB: แดง-เขียว-น้ำเงิน)
สำคัญ: ในการทำเหมืองข้อมูล เรามักใช้ AI (เช่น Deep Learning) เข้ามาช่วย "มอง"
เพื่อจำแนกวัตถุในภาพ (เช่น แยกภาพหมาออกจากแมว หรือตรวจจับสนามแม่เหล็กจากฟิล์ม X-ray)

□ Video data: ข้อมูลวิดีโอ

คือ Multimedia ที่รวมทั้ง "ภาพเคลื่อนไหว" (Image Sequence) และ "เสียง" (Audio) เข้าด้วยกัน
ความซับซ้อน: เป็นข้อมูลที่ใหญ่ที่สุดและจัดการยากที่สุด เพราะต้องวิเคราะห์ทั้งสิ่งที่อยู่ในภาพ (Spatial) และการเปลี่ยนแปลงตามเวลา (Temporal) ไปพร้อมๆ กัน

Important Characteristics of Structured Data

คุณลักษณะสำคัญของข้อมูลโครงสร้าง

□ Dimensionality มิติ

ดูว่ามีจำนวน Attributes (คอลัมน์) เยอะไหม? ถ้าเยอะเกินไปจะวิเคราะห์ยาก

□ Curse of dimensionality

□ Sparsity ความเบาบาง

ดูว่าข้อมูลส่วนใหญ่เป็น 0 หรือค่าว่างเยอะไหม? (เช่น ข้อมูลการซื้อของที่คนส่วนใหญ่ซื้อสินค้าแค่ไม่กี่อย่างจากสินค้าทั้งหมด) ซึ่งเราจะสนใจนับเฉพาะค่าที่มีอยู่จริง (Only presence counts)

□ Only presence counts

□ Resolution ความละเอียด

รูปแบบ (Pattern) ของข้อมูลอาจเปลี่ยนไปตามระดับความละเอียดที่เรามอง (เช่น ดูกราฟรายชั่วโมง กับ รายเดือน อาจเห็นแนวโน้มไม่เหมือนกัน)

□ Patterns depend on the scale

□ Distribution การแจกแจง

ดูค่ากลาง (Centrality) และการกระจายตัว (Dispersion) ของข้อมูล

□ Centrality and dispersion

Data Objects

วัตถุข้อมูล

- ❑ Data sets are made up of data objects
- ❑ A **data object** represents an entity
- ❑ Examples:
 - ❑ sales database: customers, store items, sales
 - ❑ medical database: patients, treatments
 - ❑ university database: students, professors, courses
- ❑ Also called *samples*, *examples*, *instances*, *data points*, *objects*, *tuples*
- ❑ Data objects are described by **attributes**
- ❑ Database rows → data objects; columns → attributes

Attributes คุณลักษณะ

❑ Attribute (or dimensions, features, variables)

- ❑ A data field, representing a characteristic or feature of a data object.

- ❑ *E.g., customer_ID, name, address*

❑ Types:

คือ "ฟิลด์ข้อมูล" ที่ใช้บอกลักษณะของวัตถุ (เปรียบเทียบ "คอลัมน์" ในตาราง)
เรียกได้หลายชื่อ: dimensions (มิติ), features (ฟีเจอร์), variables (ตัวแปร)

- ❑ Nominal (e.g., red, blue)

- ❑ Binary (e.g., {true, false})

- ❑ Ordinal (e.g., {freshman, sophomore, junior, senior})

- ❑ Numeric: quantitative

- ❑ Interval-scaled: 100°C is interval scales

- ❑ Ratio-scaled: 100°K is ratio scaled since it is twice as high as 50 °K

- ❑ Q1: Is student ID a nominal, ordinal, or interval-scaled data?

- ❑ Q2: What about eye color? Or color in the color spectrum of physics?

Attribute Types

(นามบัญญัติ/กลุ่ม)

❑ **Nominal:** categories, states, or “names of things”

- ❑ *Hair_color* = {auburn, black, blond, brown, grey, red, white}
- ❑ marital status, occupation, ID numbers, zip codes

❑ **Binary** (ทวิภาค/มี 2 ค่า)

- ❑ Nominal attribute with only 2 states (0 and 1)
- ❑ Symmetric binary: both outcomes equally important
 - ❑ e.g., gender
- ❑ Asymmetric binary: outcomes not equally important.
 - ❑ e.g., medical test (positive vs. negative)
 - ❑ Convention: assign 1 to most important outcome (e.g., HIV positive)

❑ **Ordinal** (เรียงลำดับ)

- ❑ Values have a meaningful order (ranking) but magnitude between successive values is not known
- ❑ *Size* = {small, medium, large}, grades, army rankings

Numeric Attribute Types

- ❑ Quantity (integer or real-valued)
- ❑ **Interval** (อันตรภาค): ไม่มีศูนย์แท้ (0 ไม่ได้แปลว่าไม่มี) เปรียบเทียบอัตราส่วนไม่ได้
 - ❑ Measured on a scale of **equal-sized units**
 - ❑ Values have order
 - ❑ E.g., *temperature in C° or F°, calendar dates*
 - ❑ No true zero-point
- ❑ **Ratio** (อัตราส่วน): มีศูนย์แท้ เปรียบเทียบเท่าตัวได้
 - ❑ Inherent **zero-point**
 - ❑ We can speak of values as being an order of magnitude larger than the unit of measurement (10 K° is twice as high as 5 K°).
 - ❑ e.g., *temperature in Kelvin, length, counts, monetary quantities*

Discrete vs. Continuous Attributes

❑ Discrete Attribute (ข้อมูลแบบไม่ต่อเนื่อง)

- ❑ Has only a finite or countably infinite set of values ลักษณะ: มีค่าที่นับได้ หรือมีจำนวนจำกัด
 - ❑ E.g., zip codes, profession, or the set of words in a collection of documents
ตัวอย่าง: รหัสไปรษณีย์, อาชีพ, ชุดคำศัพท์ในเอกสาร
 - ❑ Sometimes, represented as integer variables
การเก็บข้อมูล: มักเก็บเป็นตัวเลขจำนวนเต็ม (Integer)
 - ❑ Note: Binary attributes are a special case of discrete attributes
หมายเหตุ: ข้อมูลแบบ Binary (มี 2 ค่า) ก็ถือเป็นแบบนี้ด้วย

❑ Continuous Attribute (ข้อมูลแบบต่อเนื่อง)

- ❑ Has real numbers as attribute values ลักษณะ: เป็นตัวเลขจำนวนจริง (Real numbers) มีค่าต่อเนื่องกันไปเรื่อยๆ
 - ❑ E.g., temperature, height, or weight
ตัวอย่าง: อุณหภูมิ, ส่วนสูง, น้ำหนัก
 - ❑ Practically, real values can only be measured and represented using a finite number of digits
 - ❑ Continuous attributes are typically represented as floating-point variables
การเก็บข้อมูล: มักเก็บเป็นทศนิยม (Floating-point)

สรุปง่ายๆ: ถ้า "นับเป็นชิ้นๆ ได้" = Discrete,
ถ้า "วัดละเอียดเป็นทศนิยมได้" = Continuous ครับ

Chapter 2. Getting to Know Your Data

- ❑ Data Objects and Attribute Types
- ❑ Basic Statistical Descriptions of Data 
- ❑ Data Visualization
- ❑ Measuring Data Similarity and Dissimilarity
- ❑ Summary

Basic Statistical Descriptions of Data

- Motivation ทำไปทำไม? (Motivation) เพื่อเข้าใจธรรมชาติของข้อมูลใน 2 ด้านหลัก: Central tendency: ข้อมูลเกาะกลุ่มกันตรงไหน (ค่ากลาง)
Variation & Spread: ข้อมูลกระจายตัวมากน้อยแค่ไหน

- To better understand the data: central tendency, variation and spread

- Data dispersion characteristics

- Median, max, min, quantiles, outliers, variance, ...

- Numerical dimensions correspond to sorted intervals

- Data dispersion:

- Analyzed with multiple granularities of precision


- Boxplot or quantile analysis on sorted intervals

- Dispersion analysis on computed measures

- Folding measures into numerical dimensions

- Boxplot or quantile analysis on the transformed cube

Boxplot: เป็นกราฟหัวใจสำคัญที่ใช้วิเคราะห์การกระจายตัวของข้อมูลที่เรียงลำดับแล้ว (Sorted intervals) และใช้จับผิด Outliers ได้ดีที่สุด



Measuring the Central Tendency: (1) Mean

- Mean (algebraic measure) (sample vs. population):

Note: n is sample size and N is population size.


$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$


$$\mu = \frac{\sum x}{N}$$

- Weighted arithmetic mean:


$$\bar{x} = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

- Trimmed mean:

- Chopping extreme values (e.g., Olympics gymnastics score computation)

Measuring the Central Tendency: (2) Median

□ Median:

- Middle value if odd number of values, or average of the middle two values otherwise
- Estimated by interpolation (for *grouped data*):

<i>age</i>	<i>frequency</i>
1–5	200
6–15	450
16–20	300
21–50	1500
51–80	700
81–110	44

Approximate median

Sum before the median interval

Interval width ($L_2 - L_1$)

$$median = L_1 + \left(\frac{n/2 - (\sum freq)_l}{freq_{median}} \right) width$$

Low interval limit


Measuring the Central Tendency: (3) Mode

□ Mode: Value that occurs most frequently in the data

□ Unimodal


□ Empirical formula:

$$mean - mode = 3 \times (mean - median)$$





□ Multi-modal

□ Bimodal






□ Trimodal




Symmetric vs. Skewed Data

- Median, mean and mode of symmetric, positively and negatively skewed data



Properties of Normal Distribution Curve

← — — — — Represent data dispersion, spread — — — — →



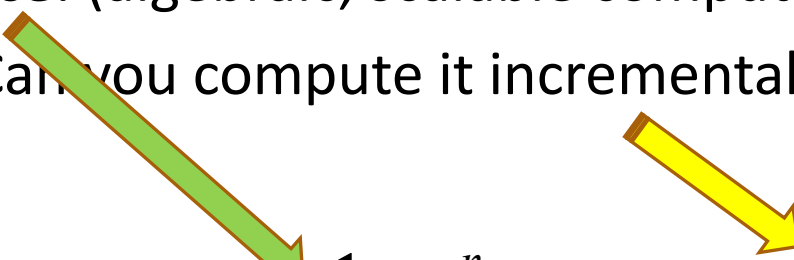
Represent central tendency

Measures Data Distribution: Variance and Standard Deviation

□ Variance and standard deviation (*sample: s , population: σ*)

□ **Variance:** (algebraic, scalable computation)

□ Q: Can you compute it incrementally and efficiently?


$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right]$$

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{N} \sum_{i=1}^n x_i^2 - \mu^2$$


□ **Standard deviation s (or σ)** is the square root of variance s^2 (or σ^2)

Graphic Displays of Basic Statistical Descriptions


- ❑ **Boxplot:** graphic display of five-number summary
- ❑ **Histogram:** x-axis are values, y-axis repres. frequencies
- ❑ **Quantile plot:** each value x_i is paired with f_i indicating that approximately $100 f_i \%$ of data are $\leq x_i$
- ❑ **Quantile-quantile (q-q) plot:** graphs the quantiles of one univariant distribution against the corresponding quantiles of another
- ❑ **Scatter plot:** each pair of values is a pair of coordinates and plotted as points in the plane

Measuring the Dispersion of Data: Quartiles & Boxplots

- ❑ **Quartiles:** Q_1 (25th percentile), Q_3 (75th percentile)
- ❑ **Inter-quartile range:** $IQR = Q_3 - Q_1$
- ❑ **Five number summary:** min, Q_1 , median, Q_3 , max
- ❑ **Boxplot:** Data is represented with a box
 - ❑ Q_1 , Q_3 , IQR: The ends of the box are at the first and third quartiles, i.e., the height of the box is IQR
 - ❑ Median (Q_2) is marked by a line within the box
 - ❑ Whiskers: two lines outside the box extended to Minimum and Maximum
 - ❑ Outliers: points beyond a specified outlier threshold, plotted individually
 - ❑ **Outlier:** usually, a value higher/lower than $1.5 \times IQR$




Visualization of Data Dispersion: 3-D Boxplots




Histogram Analysis

- ❑ Histogram: Graph display of tabulated frequencies, shown as bars
- ❑ Differences between histograms and bar charts
 - ❑ Histograms are used to show distributions of variables while bar charts are used to compare variables
 - ❑ Histograms plot binned quantitative data while bar charts plot categorical data
 - ❑ Bars can be reordered in bar charts but not in histograms
 - ❑ Differs from a bar chart in that it is the area of the bar that denotes the value, not the height as in bar charts, a crucial distinction when the categories are not of uniform width

Histogram





Olympic Medals of all Times (till 2012 Olympics)



Bar chart



Histograms Often Tell More than Boxplots






- The two histograms shown in the left may have the same boxplot representation
- The same values for: min, Q1, median, Q3, max
- But they have rather different data distributions

Scatter plot

- ❑ Provides a first look at bivariate data to see clusters of points, outliers, etc.
- ❑ Each pair of values is treated as a pair of coordinates and plotted as points in the plane




Positively and Negatively Correlated Data




- ❑ The left half fragment is positively correlated
- ❑ The right half is negative correlated

Uncorrelated Data



Chapter 2. Getting to Know Your Data

- ❑ Data Objects and Attribute Types
- ❑ Basic Statistical Descriptions of Data
- ❑ Data Visualization 
- ❑ Measuring Data Similarity and Dissimilarity
- ❑ Summary

Data Visualization

เราแปลงข้อมูลเป็นกราฟเพื่อ:
เห็นภาพรวม (Overview):
ช่วยให้เข้าใจข้อมูลขนาดใหญ่ได้ง่ายและรวดเร็ว

หาความลับ (Insights): ค้นหารูปแบบ (Patterns), แนวโน้ม (Trends), หรือความสัมพันธ์ที่ซ่อนอยู่
ซึ่งมองด้วยตาเปล่าจากตารางตัวเลขไม่เห็น

ชี้เป้า (Focus): ช่วยระบุจุดที่น่าสนใจเพื่อนำไปวิเคราะห์เจาะลึกต่อ

□ Why data visualization?

- **Gain insight** into an information space by mapping data onto graphical primitives
- **Provide qualitative overview** of large data sets
- **Search for patterns**, trends, structure, irregularities, relationships among data
- **Help find interesting regions and suitable parameters** for further quantitative analysis
- **Provide a visual proof** of computer representations derived


สรุป: คือการใช้ "ภาพ" ช่วยให้สมองมนุษย์ประมวลผลข้อมูลมหาศาลได้ทันที

□ Categorization of visualization methods:

- **Pixel-oriented** visualization techniques ใช้จุดสีแทนข้อมูล (เน้นข้อมูลหนาแน่น)
- **Geometric projection** visualization techniques Geometric projection: การฉายภาพทางเรขาคณิต (เช่น Scatter plot)
- **Icon-based** visualization techniques ใช้สัญลักษณ์/ไอคอนแทนข้อมูล (เช่น หน้าคนยิ้ม/บึ้ง)
- **Hierarchical** visualization techniques แสดงข้อมูลเป็นลำดับชั้น (เช่น Tree map)
- **Visualizing complex data and relations** สำหรับข้อมูลซับซ้อนและความสัมพันธ์ที่ยุ่งเหยิง

Pixel-Oriented Visualization Techniques


- ❑ For a data set of m dimensions, create m windows on the screen, one for each dimension
- ❑ The m dimension values of a record are mapped to m pixels at the corresponding positions in the windows
- ❑ The colors of the pixels reflect the corresponding values



(a) Income



(b) Credit Limit




(c) transaction volume




(d) age

Parallel Coordinates

- n equidistant axes which are parallel to one of the screen axes and correspond to the attributes
- The axes are scaled to the [minimum, maximum]: range of the corresponding attribute
- Every data item corresponds to a polygonal line which intersects each of the axes at the point which corresponds to the value for the attribute




Parallel Coordinates of a Data Set




Tree-Map

- ❑ Screen-filling method which uses a hierarchical partitioning of the screen into regions depending on the attribute values
- ❑ The x- and y-dimension of the screen are partitioned alternately according to the attribute values (classes)



Schneiderman@UMD: Tree-Map of a File System



Schneiderman@UMD: Tree-Map to support large data sets of a million items

Visualizing Complex Data and Relations: Tag Cloud

- ❑ **Tag cloud**: Visualizing user-generated tags
 - ❑ The importance of tag is represented by font size/color
 - ❑ Popularly used to visualize word/phrase distributions




KDD 2013 Research Paper Title Tag Cloud




Newsmap: Google News Stories in 2005

Visualizing Complex Data and Relations: Social Networks


- Visualizing non-numerical data: **social and information networks**




A typical network structure



A social network



Chapter 2. Getting to Know Your Data

- ❑ Data Objects and Attribute Types
- ❑ Basic Statistical Descriptions of Data
- ❑ Data Visualization
- ❑ Measuring Data Similarity and Dissimilarity 
- ❑ Summary

Similarity, Dissimilarity, and Proximity

(ความเหมือน

□ Similarity measure or similarity function

ใช้วัดว่าข้อมูล 2 ตัว "เหมือนกัน" แค่ไหน

กฎ: ค่า ยิ่งสูง = ยิ่งเหมือน

ช่วงค่า: มักอยู่ระหว่าง $[0, 1]$ (โดย 0 = ไม่เหมือนเลย, 1 = เหมือนเป๊ะ)

- A real-valued function that quantifies the similarity between two objects
- Measure how two data objects are alike: The higher value, the more alike
- Often falls in the range $[0,1]$: 0 : no similarity; 1 : completely similar

□ Dissimilarity (or distance) measure

ความต่าง / ระยะห่าง

ใช้วัดว่าข้อมูล 2 ตัว "ต่างกัน" แค่ไหน (ตรงข้ามกับความเหมือน)

กฎ: ค่า ยิ่งต่ำ = ยิ่งเหมือนค่าต่ำสุด: คือ 0 (แปลว่าเหมือนกันเป๊ะ ระยะห่างเป็นศูนย์)

ช่วงค่า: อาจเป็น $[0, 1]$ หรือ $[0, \infty)$ ก็ได้

- Numerical measure of how different two data objects are
- In some sense, the inverse of similarity: The lower, the more alike
- Minimum dissimilarity is often 0 (i.e., completely similar)
- Range $[0, 1]$ or $[0, \infty)$, depending on the definition

ความใกล้เคียง


□ Proximity usually refers to either similarity or dissimilarity

เป็น "ค่ากลางๆ" ที่ใช้เรียกแทนได้ทั้ง Similarity หรือ Dissimilarity ครับ

Data Matrix and Dissimilarity Matrix

- Data matrix

- A data matrix of n data points with l dimensions


$$D = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1l} \\ x_{21} & x_{22} & \dots & x_{2l} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nl} \end{pmatrix}$$


- Dissimilarity (distance) matrix

- n data points, but registers only the distance $d(i, j)$ (typically metric)

- Usually symmetric, thus a triangular matrix

- **Distance functions** are usually different for real, boolean, categorical, ordinal, ratio, and vector variables

- Weights can be associated with different variables based on applications and data semantics


$$\begin{pmatrix} 0 & & & \\ d(2,1) & 0 & & \\ \vdots & \vdots & \ddots & \\ d(n,1) & d(n,2) & \dots & 0 \end{pmatrix}$$

Standardizing Numeric Data

- Z-score:
$$z = \frac{x - \mu}{\sigma}$$
 - X: raw score to be standardized, μ : mean of the population, σ : standard deviation
 - the distance between the raw score and the population mean in units of the standard deviation
 - negative when the raw score is below the mean, “+” when above

- An alternative way: Calculate the mean absolute deviation


$$s_f = \frac{1}{n} (|x_{1f} - m_f| + |x_{2f} - m_f| + \dots + |x_{nf} - m_f|)$$

where

$$m_f = \frac{1}{n} (x_{1f} + x_{2f} + \dots + x_{nf}).$$

- standardized measure (z-score):
$$z_{if} = \frac{x_{if} - m_f}{s_f}$$
- Using mean absolute deviation is more robust than using standard deviation

Example: Data Matrix and Dissimilarity Matrix



Data Matrix

point	attribute1	attribute2
$x1$	1	2
$x2$	3	5
$x3$	2	0
$x4$	4	5

Dissimilarity Matrix (by **Euclidean Distance**)

	$x1$	$x2$	$x3$	$x4$
$x1$	0			
$x2$	3.61	0		
$x3$	2.24	5.1	0	
$x4$	4.24	1	5.39	0

Distance on Numeric Data: Minkowski Distance

- **Minkowski distance**: A popular distance measure

$$d(i, j) = \sqrt[p]{|x_{i1} - x_{j1}|^p + |x_{i2} - x_{j2}|^p + \dots + |x_{il} - x_{jl}|^p}$$

where $i = (x_{i1}, x_{i2}, \dots, x_{il})$ and $j = (x_{j1}, x_{j2}, \dots, x_{jl})$ are two l -dimensional data objects, and p is the order (the distance so defined is also called L- p norm)

- Properties
 - $d(i, j) > 0$ if $i \neq j$, and $d(i, i) = 0$ (Positivity)
 - $d(i, j) = d(j, i)$ (Symmetry)
 - $d(i, j) \leq d(i, k) + d(k, j)$ (Triangle Inequality)
- A distance that satisfies these properties is a **metric**
- Note: There are nonmetric dissimilarities, e.g., set differences

Special Cases of Minkowski Distance

□ $p = 1$: (L_1 norm) **Manhattan (or city block) distance**

□ E.g., the Hamming distance: the number of bits that are different between two binary vectors

$$d(i, j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{il} - x_{jl}|$$

□ $p = 2$: (L_2 norm) **Euclidean distance**

$$d(i, j) = \sqrt{|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \cdots + |x_{il} - x_{jl}|^2}$$


□ $p \rightarrow \infty$: ($L_{\max}$ norm, L_{∞} norm) **“supremum” distance**

□ The maximum difference between any component (attribute) of the vectors

$$d(i, j) = \lim_{p \rightarrow \infty} \sqrt[p]{|x_{i1} - x_{j1}|^p + |x_{i2} - x_{j2}|^p + \cdots + |x_{il} - x_{jl}|^p} = \max_{f=1}^l |x_{if} - x_{jf}|$$

Example: Minkowski Distance at Special Cases

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5



Manhattan (L_1)

L	x1	x2	x3	x4
x1	0			
x2	5	0		
x3	3	6	0	
x4	6	1	7	0

Euclidean (L_2)

L2	x1	x2	x3	x4
x1	0			
x2	3.61	0		
x3	2.24	5.1	0	
x4	4.24	1	5.39	0

Supremum (L_∞)

L_∞	x1	x2	x3	x4
x1	0			
x2	3	0		
x3	2	5	0	
x4	3	1	5	0

Proximity Measure for Binary Attributes

- A contingency table for binary data

		Object j		
		1	0	sum
Object i	1	q	r	$q + r$
	0	s	t	$s + t$
sum		$q + s$	$r + t$	p

- Distance measure for symmetric binary variables

$$d(i, j) = \frac{r + s}{q + r + s + t}$$

- Distance measure for asymmetric binary variables:

$$d(i, j) = \frac{r + s}{q + r + s}$$

- Jaccard coefficient (*similarity* measure for *asymmetric* binary variables):

$$sim_{Jaccard}(i, j) = \frac{q}{q + r + s}$$

- Note: Jaccard coefficient is the same as

(a concept discussed in Pattern Discovery)

$$coherence(i, j) = \frac{sup(i, j)}{sup(i) + sup(j) - sup(i, j)} = \frac{q}{(q + r) + (q + s) - q}$$

Example: Dissimilarity between Asymmetric Binary Variables

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M	Y	N	P	N	N	N
Mary	F	Y	N	P	N	P	N
Jim	M	Y	P	N	N	N	N

- Gender is a symmetric attribute (not counted in)
- The remaining attributes are asymmetric binary
- Let the values Y and P be 1, and the value N be 0
- Distance: $d(i, j) = \frac{r + s}{q + r + s}$

$$d(jack, mary) = \frac{0 + 1}{2 + 0 + 1} = 0.33$$

$$d(jack, jim) = \frac{1 + 1}{1 + 1 + 1} = 0.67$$

$$d(jim, mary) = \frac{1 + 2}{1 + 1 + 2} = 0.75$$

		Mary		
		1	0	Σ_{row}
Jack	1	2	0	2
	0	1	3	4
	Σ_{col}	3	3	6

		Jim		
		1	0	Σ_{row}
Jack	1	1	1	2
	0	1	3	4
	Σ_{col}	2	4	6

		Mary		
		1	0	Σ_{row}
Jim	1	1	1	2
	0	2	2	4
	Σ_{col}	3	3	6

Proximity Measure for Categorical Attributes

- ❑ Categorical data, also called nominal attributes
 - ❑ Example: Color (red, yellow, blue, green), profession, etc.
- ❑ Method 1: Simple matching
 - ❑ m : # of matches, p : total # of variables

$$d(i, j) = \frac{p - m}{p}$$

- ❑ Method 2: Use a large number of binary attributes
 - ❑ Creating a new binary attribute for each of the M nominal states

Ordinal Variables

- ❑ An ordinal variable can be discrete or continuous
- ❑ Order is important, e.g., rank (e.g., freshman, sophomore, junior, senior)
- ❑ Can be treated like interval-scaled
 - ❑ Replace *an ordinal variable value* by its rank: $r_{if} \in \{1, \dots, M_f\}$
 - ❑ Map the range of each variable onto $[0, 1]$ by replacing i -th object in the f -th variable by
$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$
 - ❑ Example: freshman: 0; sophomore: 1/3; junior: 2/3; senior 1
 - ❑ Then distance: $d(\text{freshman}, \text{senior}) = 1$, $d(\text{junior}, \text{senior}) = 1/3$
 - ❑ Compute the dissimilarity using methods for interval-scaled variables

Attributes of Mixed Type

- A dataset may contain all attribute types
 - Nominal, symmetric binary, asymmetric binary, numeric, and ordinal
- One may use a weighted formula to combine their effects:

$$d(i, j) = \frac{\sum_{f=1}^p w_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^p w_{ij}^{(f)}}$$

- If f is numeric: Use the normalized distance
- If f is binary or nominal: $d_{ij}^{(f)} = 0$ if $x_{if} = x_{jf}$; or $d_{ij}^{(f)} = 1$ otherwise
- If f is ordinal
 - Compute ranks z_{if} (where $z_{if} = \frac{r_{if} - 1}{M_f - 1}$)
 - Treat z_{if} as interval-scaled

Cosine Similarity of Two Vectors

- A **document** can be represented by a bag of terms or a long vector, with each attribute recording the *frequency* of a particular term (such as word, keyword, or phrase) in the document


Document	team	coach	hockey	baseball	soccer	penalty	score	win	loss	season
Document1	5	0	3	0	2	0	0	2	0	0
Document2	3	0	2	0	1	1	0	1	0	1
Document3	0	7	0	2	1	0	0	3	0	0
Document4	0	1	0	0	1	2	2	0	3	0

- Other vector objects: Gene features in micro-arrays
- Applications: Information retrieval, biologic taxonomy, gene feature mapping, etc.
- Cosine measure: If d_1 and d_2 are two vectors (e.g., term-frequency vectors), then

$$\cos(d_1, d_2) = \frac{d_1 \bullet d_2}{\|d_1\| \times \|d_2\|}$$

where $\bullet$ indicates vector dot product, $\|d\|$: the length of vector d

Example: Calculating Cosine Similarity



□ Calculating Cosine Similarity:
$$\cos(d_1, d_2) = \frac{d_1 \bullet d_2}{\|d_1\| \times \|d_2\|} \quad \text{sim}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

where $\bullet$ indicates vector dot product, $\|d\|$: the length of vector d

- Ex: Find the **similarity** between documents 1 and 2.

$$d_1 = (5, 0, 3, 0, 2, 0, 0, 2, 0, 0) \quad d_2 = (3, 0, 2, 0, 1, 1, 0, 1, 0, 1)$$

- First, calculate vector dot product

$$d_1 \bullet d_2 = 5 \times 3 + 0 \times 0 + 3 \times 2 + 0 \times 0 + 2 \times 1 + 0 \times 1 + 0 \times 1 + 2 \times 1 + 0 \times 0 + 0 \times 1 = 25$$

- Then, calculate $\|d_1\|$ and $\|d_2\|$

$$\|d_1\| = \sqrt{5 \times 5 + 0 \times 0 + 3 \times 3 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 0 \times 0} = 6.481$$

$$\|d_2\| = \sqrt{3 \times 3 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 1 \times 1 + 1 \times 1 + 0 \times 0 + 1 \times 1 + 0 \times 0 + 1 \times 1} = 4.12$$

- Calculate cosine similarity: $\cos(d_1, d_2) = 25 / (6.481 \times 4.12) = 0.94$

Chapter 2. Getting to Know Your Data

- ❑ Data Objects and Attribute Types
- ❑ Basic Statistical Descriptions of Data
- ❑ Data Visualization
- ❑ Measuring Data Similarity and Dissimilarity
- ❑ Summary 

Summary

- ❑ Data attribute types: nominal, binary, ordinal, interval-scaled, ratio-scaled
- ❑ Many types of data sets, e.g., numerical, text, graph, Web, image.
- ❑ Gain insight into the data by:
 - ❑ Basic statistical data description: central tendency, dispersion, graphical displays
 - ❑ Data visualization: map data onto graphical primitives
 - ❑ Measure data similarity
- ❑ Above steps are the beginning of data preprocessing
- ❑ Many methods have been developed but still an active area of research

1. รู้จักประเภทข้อมูล (Attribute Types): เราต้องแยกแยะข้อมูลให้เป็น 5 ประเภทหลัก คือ Nominal (ชื่อกลุ่ม), Binary (2 ค่า), Ordinal (ลำดับ), Interval (ช่วงอุณหภูมิ), และ Ratio (สัดส่วนตัวเลข)

2. รู้จักรูปแบบข้อมูล (Data Sets): ข้อมูลไม่ได้มีแค่ตารางตัวเลข แต่ยังมีรูปแบบอื่นๆ อีกมาก เช่น ข้อความ (Text), กราฟ (Graph), ข้อมูลเว็บ (Web), และรูปภาพ

3. วิธีเจาะลึกข้อมูล (Gaining Insight): เพื่อให้เข้าใจข้อมูลอย่างถ่องแท้ เราใช้ 3 เครื่องมือหลัก:

- สถิติ (Statistics): ค่ากลาง (Central Tendency) และการกระจายตัว (Dispersion)
- การสร้างภาพ (Visualization): แปลงข้อมูลเป็นกราฟ
- การวัดความเหมือน (Similarity): คำนวณระยะห่างระหว่างข้อมูล

4. จุดยืนสำคัญ: ขั้นตอนทั้งหมดในบทนี้ คือจุดเริ่มต้นของการ "การเตรียมข้อมูล" (Data Preprocessing) ซึ่งเป็นงานวิจัยที่ยังมีการพัฒนาเทคนิคใหม่ๆ อยู่อย่างต่อเนื่องครับ

References

- ❑ W. Cleveland, Visualizing Data, Hobart Press, 1993
- ❑ T. Dasu and T. Johnson. Exploratory Data Mining and Data Cleaning. John Wiley, 2003
- ❑ U. Fayyad, G. Grinstein, and A. Wierse. Information Visualization in Data Mining and Knowledge Discovery, Morgan Kaufmann, 2001
- ❑ L. Kaufman and P. J. Rousseeuw. Finding Groups in Data: an Introduction to Cluster Analysis. John Wiley & Sons, 1990.
- ❑ H. V. Jagadish et al., Special Issue on Data Reduction Techniques. Bulletin of the Tech. Committee on Data Eng., 20(4), Dec. 1997
- ❑ D. A. Keim. Information visualization and visual data mining, IEEE trans. on Visualization and Computer Graphics, 8(1), 2002
- ❑ D. Pyle. Data Preparation for Data Mining. Morgan Kaufmann, 1999
- ❑ S. Santini and R. Jain, "Similarity measures", IEEE Trans. on Pattern Analysis and Machine Intelligence, 21(9), 1999
- ❑ E. R. Tufte. The Visual Display of Quantitative Information, 2nd ed., Graphics Press, 2001
- ❑ C. Yu, et al., Visual data mining of multimedia data for social and behavioral studies, Information Visualization, 8(1), 2009

